응답 지연 시간(Latency) 및 p95 분석 보고서

본 문서는 동시성 제어(Concurrency Control) 방식(Pessimistic Lock, Spin Lock, Pub/Sub Lock)에 따른 응답 지연 시간(Mean Latency)과 꼬리 지연 시간(p95 Tail Latency)을 분석한 결과입니다. 본 데이터는 앞서 진행된 TPS 분석 보고서와 교차 검증하여 작성되었습니다.

1. 종합 지표 요약

Lock	Vuser	Worst Mean Latency	Overall Mean Latency	Best Mean Latency	p95 Tail Latency
Pessimistic Lock	500	732.61	556.58	409.65	1300.69
	800	1303.32	1041.69	828.86	1999.17
	1000	1124.91	1012.86	764.98	2093.91
Spin Lock	500	712.17	598.21	388.85	1359.33
	800	1197.05	1049.31	846.03	1980.9
	1000	1234.61	1117.89	911.19	2147.73
Pub/Sub Lock	500	814.15	541.12	332.8	1242.14
	800	1140.96	973.87	759.43	1911.78
	1000	1490.58	1152.08	1027.28	2168.78

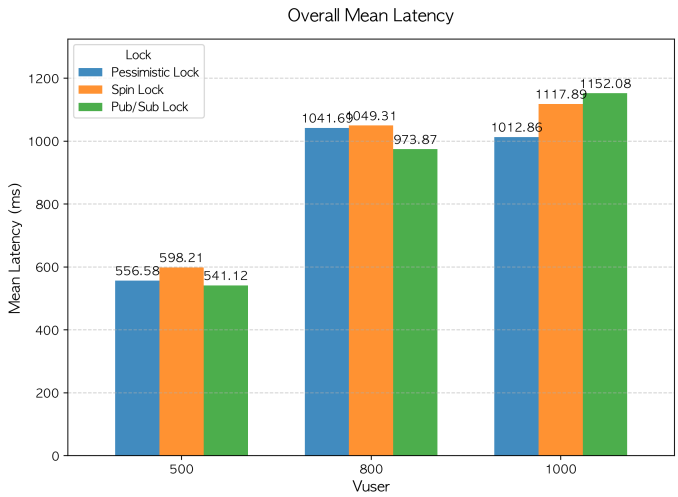

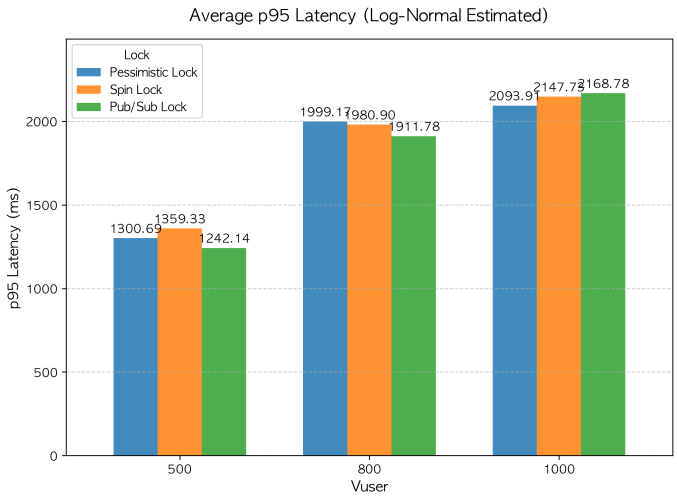

2. Lock 별 성능 분석

Pessimistic Lock

- **응답 속도:** Vuser 800(1041.69 ms)에서 Vuser 1000(1012.86 ms)으로 부하가 증가했음에도 평균 지연 시간이 오히려 소폭 감소하거나 정체하는 기현상이 나타남.

- **원인 분석(시스템 파이프라인 포화 현상):**
  - 실제 로그 확인 결과 Timeout Error 비율은 극히 미미했으므로, 에러 발생으로 인한 생존자 편향(Survivor Bias)은 아님.
  - Vuser 800 이상부터 평균 지연 시간이 정체된 것은 **애플리케이션의 Tomcat 스레드 풀(Max 200) 및 DB 커넥션 풀(Max 150)이 동시에 수용할 수 있는 동시성 임계점에 도달**했기 때문임.
- **대기열 이론(Queueing Theory) 적용 심층 분석:**
  - Vuser 800이든 1000이든 시스템 내부에서 실제로 DB Lock을 두고 경합하는 스레드의 수는 최대 150개(DB 커넥션 한계)로 동일함.
  - **컨텍스트 스위칭 오버헤드:** 제한된 CPU 자원(컨테이너당 2 Core)이 150개의 DB 커넥션(스레드)을 번갈아가며 처리하느라 상태를 저장하고 불러오는 작업에 자원을 크게 낭비하게 되어, 실제 쿼리 처리 효율이 극도로 저하됨.
  - 현재 애플리케이션의 설정상 수용 가능한 **물리적 최대 대기/처리 한계선은 총 700개**임. (Tomcat 스레드 `threads.max` 200개 + 대기열 큐 `accept-count` 500개)
  - Vuser 800에서 1000으로 외부 부하가 늘어나도, 서버 내부의 대기열은 이미 최대치(700개)에 도달해 테스트 내내 100% 포화 상태를 유지함.
  - **평균 지연 시간의 정체 원리:** 1041.69 ms는 700명 규모의 포화된 파이프라인을 거쳐 간 **모든 요청의 평균(Mean) 대기 시간**임. 따라서 테스트를 진행하는 요청들의 평균 대기 시간 역시 물리적 한계점(약 1000 ms 부근)으로 고정된 것임. (1041 ms와 1012 ms의 미세한 차이는 통계적 오차로 간주)
  - 다중 WAS 환경(WAS 2대)에서 총 300개의 커넥션이 MySQL의 단일 레코드(`courseId: 1`)를 갱신하기 위해 경합하면서 발생하는 '핫 로우 경합'이 근본적인 병목 원인으로 지목됨.

Spin Lock

- **응답 속도:** Vuser 500 구간(598.21 ms)에서 다른 두 락 방식 대비 가장 느린 평균 응답 시간 기록
- **p95 꼬리 지연 시간 분석:** 부하가 증가할수록 p95 지연 시간이 1359.33 ms → 1980.90 ms → 2147.73 ms로 가파르게 상승
- **원인 분석:**
  - 락을 획득하기 위해 스레드가 쉴 새 없이 상태를 확인하는 구조 탓에 CPU 점유율과 경합 심화됨
  - 제한된 CPU 자원(컨테이너당 2 Core) 환경에서 부하가 가중될수록 잦은 컨텍스트 스위칭 오버헤드가 발생하며, 락을 늦게 획득하는 스레드들의 대기 시간이 기하급수적으로 늘어나 응답 시간의 편차가 크게 벌어지는 약점을 보임.

Pub/Sub Lock

- **응답 속도:** 저부하(Vuser 500) 및 중부하(Vuser 800) 상황에서 전체 평균 지연 시간이 각각 541.12 ms, 973.87 ms로 **가장 빠르고 안정적인 응답 속도** 보임
- **고부하(Vuser 1000) 현상:** Vuser 1000에서는 평균 지연 시간(1152.08 ms)과 p95(2168.78 ms)가 3가지 방식 중 가장 높게 측정됨.
- **원인 분석:**
  - 다른 락들은 DB 자원 병목으로 인해 한계 처리량(TPS)이 정체된 반면, Pub/Sub Lock은 인메모리를 활용한 효율적인 이벤트 대기 방식을 통해 병목 없이 **가장 많은 요청을 성공적으로 소화(최고 TPS 기록)했기 때문**임.
  - 끝까지 큐에서 대기하여 가장 많은 사람에게 응답을 주었으므로, 필연적으로 대기열 후미에 있던 요청들의 긴 대기 시간이 통계에 반영되어 Latency가 가장 길게 측정됨.
  - 즉, 시스템이 병목에 빠지지 않고 유연하게 확장하고 있다고 볼 수 있음.

---

3. 결론 및 인사이트

1. **DB 락의 스케일 아웃 한계 증명:** 다중 WAS 및 로드밸런서 환경에서 단일 레코드에 대한 `Pessimistic Lock` 제어 방식은 트래픽 폭증 시 DB 커넥션 풀을 과점유하여 전체 시스템의 파이프라인을 마비시킴.
2. **분산 락의 우수성 확인:** 인메모리 기반의 `Pub/Sub Lock`은 극한의 핫 로우 경합 상황에서도 DB에 직접적인 부하를 주지 않고 WAS 단에서 이벤트를 대기하므로, 시스템 다운이나 병목 현상 없이 가장 안정적이고 높은 확장성을 보여줌.
3. **한계점 및 향후 과제:** 본 테스트의 Vuser 800, 1000 구간에서 지연 시간이 역전되거나 정체된 현상은 시스템 물리적 수용 한계 도달에 의한 것으로 확인됨. 추후 더 극단적인 부하 한계를 확인하기 위해서는 WAS의 CPU 할당량과 Tomcat 대기열 확장을 고려해 볼 수 있으나, 현재의 설정이 한정된 자원 내에서의 알고리즘 성능 비교 목적에는 가장 적합한 환경임을 확인함.